

BERT 医疗文本分类三种训练策略对比

任务: KUAKE-QIC 中文医疗搜索意图 11 分类
数据: 训练 1,368 / 验证 293 / 测试 294

设备: RTX 4060 Laptop GPU (8GB)
设置: BERT-base-chinese, FP16, 8 epochs, seed 42

核心结果

策略	Accuracy	Macro-F1	训练时间	峰值显存	可训练参数
随机初始化 BERT	68.37%	45.49%	74.89 秒	1,807.7 MB	102.28M (100%)
冻结预训练 BERT	59.52%	35.32%	30.42 秒	453.2 MB	8,459 (0.0083%)
预训练 BERT + LoRA	77.21%	56.94%	67.55 秒	913.0 MB	303,371 (0.2957%)

训练时间仅含 Trainer.train(); 峰值显存为 torch.cuda.max_memory_allocated()。类别不平衡, 因此 Macro-F1 比单独 Accuracy 更能反映整体分类能力。

差异分析

随机初始化

全参数训练可拟合高频类别, 但小数据不足以从零学习稳定语言表示。效果高于冻结策略, 却需要最多参数、时间与显存。

冻结微调

只训练分类头, 速度最快、显存最低。固定通用表示无法充分适应细粒度医疗意图, 因此 Accuracy 与 Macro-F1 均最低。

LoRA

仅训练 0.30% 参数并保留预训练知识。相比随机初始化, Accuracy +8.84 个百分点, 显存降低约 49.5%, 综合表现最佳。

适用场景

策略	适合	主要限制
随机初始化	教学对照、验证预训练价值、拥有海量领域语料	小数据下效果与资源效率较差
冻结微调	极低显存、快速原型、最低成本基线	领域适应能力有限
LoRA	小中型领域数据、多任务 Adapter、有限 GPU	极大规模领域迁移可能仍需全量微调

结论: 当前小规模中文医疗分类任务应优先采用 LoRA; 冻结微调适合作为低成本基线, 随机初始化主要用于实验对照。

W&B: [项目总览](#) | [汇总对比](#) | [随机初始化](#) | [冻结](#) | [LoRA](#)